

“Reporte de Predicción de la Progresión de la Diabetes mediante Regresión Lineal”

Proyecto de Análisis de Datos

Autor:

Hurtado Ramos Arianna Monserratt

Introducción

El objetivo principal del análisis es predecir la progresión de la diabetes (la variable target) en función de las otras variables, que son características demográficas y biomédicas de los pacientes, pues se utiliza comúnmente en problemas de regresión para tratar de predecir un valor numérico. Debido a su relevancia, este conjunto de datos se utiliza ampliamente en la investigación y la enseñanza de la ciencia de datos y el aprendizaje automático en el campo de la salud.

Se tomaron en cuenta las siguientes características:

- **Age:** edad del paciente en años
- **S6:** medida de la concentración de plasma de insulina
- **Target:** medida cuantitativa de la progresión de la enfermedad diabetes después de un año
- **Sex:** sexo biológico del paciente (0 = Masculino, 1 = Femenino)
- **BMI:** Índice de Masa Corporal (IMC) del paciente
- **BP:** presión sanguínea media del paciente
- **S1:** nivel de concentración de plasma de glucosa en ayunas
- **S2:** nivel de lipoproteína de alta densidad (HDL)
- **S3:** nivel de lipoproteína de baja densidad (LDL)
- **S4:** nivel de total de colesterol en plasma
- **S5:** logaritmo natural de la concentración de triglicéridos

Para lograrlo se utilizó un modelo de **regresión lineal**, una herramienta que permite encontrar relaciones entre varios factores y estimar cómo cambian los resultados cuando alguno de ellos varía.

Metodología

En primer lugar, se cargó el conjunto de datos con la información de los pacientes y luego se realizó una preparación de los datos, la cual consiste en revisar toda la información disponible y descartar los registros incompletos, es decir, aquellos en los que faltaba algún dato importante como la edad, la presión o el nivel de glucosa o algunas de las características, ya que, si los datos no están completos, el modelo no puede aprender correctamente ni ofrecer resultados confiables.

Una vez que los datos estuvieron listos, se dividieron en dos grupos, siendo el primero el conjunto de entrenamiento, que sirve para que el modelo “aprenda” las relaciones entre las características de los pacientes y la progresión de la diabetes, mientras que el segundo corresponde al conjunto de prueba, y se usa al final para evaluar qué tan bien puede predecir el modelo en datos que nunca había visto antes, de esta forma se puede

comprobar si el modelo realmente funciona o si solo memorizó los datos del entrenamiento.

A continuación, se llevó a cabo el entrenamiento utilizando un modelo de regresión lineal, con el objetivo de que se pudiera establecer las relaciones entre las variables independientes y la progresión de la enfermedad y posteriormente se procedió a evaluar el rendimiento del modelo mediante métricas relevantes, específicamente el Error Cuadrático Medio (MSE) y el Coeficiente de determinación (R^2).

Primera etapa del análisis

Se trabajó únicamente con una variable independiente, la **edad** del paciente, y se realizó una gráfica que mostraba la relación entre la edad y el nivel de progresión de la diabetes, al observarla se notó que los puntos estaban muy dispersos, sin seguir una tendencia clara, lo que significa que la edad por sí sola no influye mucho en cómo avanza la enfermedad, ya que pacientes de diferentes edades podían tener niveles de progresión similares.

Después se evaluó el desempeño del modelo usando dos medidas importantes: el **Error Cuadrático Medio (MSE)** y el **Coeficiente de determinación (R^2)**, donde el MSE indica cuánto se equivoca el modelo en promedio, entre más bajo sea, mejor es el resultado, mientras que el R^2 indica qué tan bien el modelo logra explicar los datos, y su valor ideal se acerca al número 1, lo que significaría que el modelo es muy preciso: sin embargo, en este primer intento los valores de MSE fueron muy altos y el R^2 fue bastante bajo, lo que confirmó que la edad no era una variable útil para realizar una predicción confiable.

Segunda etapa del análisis

Debido a esto, se decidió realizar un segundo intento, esta vez seleccionando las cinco características más influyentes del conjunto de datos. Estas fueron:

- **BMI**: Índice de Masa Corporal del paciente, relacionado con el peso.
- **BP**: Presión sanguínea media.
- **S1**: Nivel de glucosa en ayunas.
- **S2**: Lipoproteína de alta densidad (HDL).
- **S3**: Lipoproteína de baja densidad (LDL).

El modelo se entrenó nuevamente usando estas variables y aunque no se generó una gráfica de dispersión, al revisar los resultados se observó una mejora notable, ya que el MSE disminuyó, lo que indica que el modelo cometía menos errores al hacer sus predicciones, y el R^2 aumentó acercándose más al valor de 1, lo que significa que el modelo ahora podía explicar mejor los datos y predecir la progresión de la diabetes con mayor precisión.

Interpretación de los resultados

En términos generales, se identificó que las características relacionadas con el peso corporal, los niveles de glucosa y algunos indicadores de la sangre son las que más influyen en la progresión de la diabetes, mientras que la edad no tiene un impacto determinante. Específicamente, el modelo muestra que los pacientes con mayor índice de masa corporal tienden a experimentar un avance más rápido de la enfermedad, lo que refleja la importancia del peso como factor de riesgo.

Asimismo, los niveles de glucosa en ayunas resultaron ser un indicador clave, dado que valores elevados se asocian con una progresión más rápida de la diabetes, lo que enfatiza la necesidad de controlar el azúcar en sangre de manera constante. Por otra parte, algunos indicadores relacionados con el colesterol y la presión sanguínea también presentan influencia, aunque en menor medida, lo que sugiere que la salud cardiovascular y la presión arterial pueden contribuir al desarrollo de complicaciones, aunque no son tan determinantes como el peso y la glucosa.

Aunque cada variable tiene un efecto diferente, el modelo permite identificar de manera clara cuáles aspectos médicos son más relevantes para anticipar la evolución de la diabetes y, por consiguiente, orientar estrategias de prevención y control específicas para cada paciente, lo que demuestra que la combinación de múltiples factores médicos proporciona una visión más completa de los riesgos que enfrentarán los pacientes en el futuro.

Conclusión

Este análisis permitió comprender que la edad no es un factor determinante en la progresión de la diabetes, mientras que los aspectos relacionados con el peso y los niveles de glucosa son los que realmente explican cómo avanza la enfermedad.

Asimismo, el modelo nos ayuda a visualizar que las personas con mayor peso corporal y niveles altos de azúcar en la sangre son las que corren un riesgo mayor de que su diabetes empeore más rápido. Aunque el modelo todavía no es perfecto, sí es una herramienta útil para anticipar posibles riesgos y orientar tanto a los médicos como a los pacientes sobre la importancia de controlar el peso y los niveles de glucosa para evitar complicaciones futuras.